Td 4

Exercice 1 :

Soient deux vecteurs de paramètres d'apprentissage dans $\mathbb{R}^3$:

$$w_A = \begin{pmatrix} 3 \\ 0 \\ -4 \end{pmatrix}, \qquad w_B = \begin{pmatrix} 2 \\ 2 \\ -2 \end{pmatrix}$$

1. **Amplitudes et distances métriques :**
   a) Calculer les normes $\|w_A\|_1$, $\|w_A\|_2$, $\|w_A\|_\infty$ ainsi que $\|w_B\|_1$, $\|w_B\|_2$, $\|w_B\|_\infty$.
   b) Évaluer la distance euclidienne $d_2(w_A, w_B)$ et la distance de Manhattan $d_1(w_A, w_B)$.
2. **Convexité native des normes :**
   a) Démontrer, en utilisant les axiomes d'homogénéité absolue et d'inégalité triangulaire, que toute norme $\|\cdot\|$ vérifie :
   $$\|\theta u + (1-\theta)v\| \leq \theta\|u\| + (1-\theta)\|v\|, \quad \forall (u,v) \in (\mathbb{R}^d)^2, \quad \forall \theta \in [0,1]$$
   b) Pourquoi cette propriété garantit-elle qu'un problème d'optimisation de la forme $\min_w \mathcal{L}(w) + \lambda\|w\|$ reste strictement tractable si la fonction de perte empirique $\mathcal{L}$ est convexe ?
3. **Descente de gradient et Weight Decay (L_2) :** On considère la fonctionnelle régularisée $\mathcal{L}_{\text{total}}(w) = \mathcal{L}(w) + \frac{\lambda}{2}\|w\|_2^2$, et la règle de mise à jour SGD s'écrit :
   $$w_{t+1} = (1 - \eta\lambda)w_t - \eta\nabla\mathcal{L}(w_t)$$
   a) À l'itération t, on donne :
   $$w_t = \begin{pmatrix} 1{,}5 \\ -2{,}0 \end{pmatrix}, \quad \nabla_w\mathcal{L}(w_t) = \begin{pmatrix} 0{,}4 \\ -0{,}8 \end{pmatrix}, \quad \eta = 0{,}1, \quad \lambda = 0{,}05$$
   Calculer explicitement les coordonnées de w_{t+1}.
   b) Comparer $\|w_t\|_2$ et $\|w_{t+1}\|_2$. Quelle composante subit la plus forte contraction due à la régularisation ?
4. **Sparsité et Opérateur de Seuillage Doux (L_1) :** L'opérateur de seuillage doux (soft-thresholding) associé à la pénalisation Lasso s'écrit coordonnée par coordonnée :
   $$\mathcal{S}_\lambda(z) = \text{sign}(z) \cdot \max(0, |z| - \lambda)$$
   Soit le vecteur non pénalisé $\hat{w} = (3{,}2,\ -0{,}4,\ 0{,}2,\ -1{,}9)^\top$. Appliquer le seuillage pour $\lambda = 0{,}5$. Quelles variables sont éliminées du modèle ?

Exercice 2 :

Un classifieur d'images reçoit en entrée un vecteur de 4 pixels normalisés $x \in [0,1]^4$. Un attaquant résout le problème d'optimisation sous contrainte de visibilité humaine :

$$\max_{\|\delta\|_\infty \leq \epsilon} \mathcal{L}(x + \delta, y)$$

On donne les paramètres suivants :

$$x = \begin{pmatrix} 0{,}82 \\ 0{,}15 \\ 0{,}40 \\ 0{,}90 \end{pmatrix}, \quad \nabla_x\mathcal{L}(x,y) = \begin{pmatrix} +0{,}75 \\ -1{,}20 \\ +0{,}00 \\ -0{,}05 \end{pmatrix}, \quad \epsilon = 0{,}04$$

1. Justifier géométriquement pourquoi la perturbation optimale sous contrainte $\|\delta\|_\infty \leq \epsilon$ est donnée par la règle de Goodfellow : $\delta^* = \epsilon \cdot \text{sign}(\nabla_x \mathcal{L})$. *(Pour la coordonnée nulle, poser* $\text{sign}(0) = 0$*).*
2. Calculer le vecteur δ^* et l'exemple altéré $x_{\text{adv}} = x + \delta^*$.
3. Vérifier que $\|\delta^*\|_\infty \leq \epsilon$ et que les composantes de x_{adv} respectent l'intervalle d'admissibilité $[0, 1]$.
4. Pourquoi une composante de gradient faible (ex : $-0{,}05$) induit-elle la même amplitude de modification qu'une composante forte (ex : $-1{,}20$) ?

Exercice 3 :

Partie A : Itération de l'algorithme K-Means (Lloyd)

Soient 4 points dans $\mathbb{R}^2$:

$$p_1 = \begin{pmatrix}1\\1\end{pmatrix}, \quad p_2 = \begin{pmatrix}2\\1\end{pmatrix}, \quad p_3 = \begin{pmatrix}4\\3\end{pmatrix}, \quad p_4 = \begin{pmatrix}5\\4\end{pmatrix}$$

Les centroïdes initiaux sont $\mu_1^{(0)} = (1, 2)^\top$ et $\mu_2^{(0)} = (5, 2)^\top$.

1. **Affectation (Étape E) :** Calculer les distances au carré $\|p_i - \mu_j^{(0)}\|_2^2$ pour chaque point et en déduire les partitions $C_1^{(0)}$ et $C_2^{(0)}$.
2. **Mise à jour (Étape M) :** Calculer les nouveaux centres $\mu_1^{(1)}$ et $\mu_2^{(1)}$ via la moyenne arithmétique.
3. Montrer analytiquement que la moyenne arithmétique $\mu^* = \frac{1}{|C|}\sum_{x \in C} x$ est le minimiseur unique de $\phi(\mu) = \sum_{x \in C} \|x - \mu\|_2^2$.

Partie B : Sensibilité de la règle des k-NN

Soit une requête de test $q = (0, 0)^\top$ et trois points étiquetés :

$$x_1 = (1, 2)^\top \ (y_1 = +1), \quad x_2 = (2, 1)^\top \ (y_2 = +1), \quad x_3 = (0, 4)^\top \ (y_3 = -1 \text{ [bruit/outlier]})$$

1. Déterminer le plus proche voisin ($k = 1$) sous la distance euclidienne d_2. Quelle classe est assignée ?
2. Déterminer le plus proche voisin ($k = 1$) sous la distance de Manhattan d_1. Quelle classe est assignée ?
3. Conclure sur le comportement comparé de L_1 et L_2 face à des axes bruités.

Exercice 4 :

Soit la matrice de poids d'une couche de réseau de neurones :

$$W = \begin{pmatrix}2 & 1\\0 & 2\end{pmatrix}$$

1. **Norme de Frobenius :**
   a) Calculer $\|W\|_F$ via la somme explicite des cases au carré.
   b) Calculer la matrice $W^\top W$.
   c) Vérifier que $\|W\|_F = \sqrt{\text{Tr}(W^\top W)}$.
2. **Norme Spectrale :**
   a) Calculer le polynôme d'état $\det(W^\top W - \lambda I) = 0$ et déterminer les valeurs propres de $W^\top W$.
   b) En déduire la norme spectrale $\|W\|_2 = \sigma_{\max}(W) = \sqrt{\lambda_{\max}(W^\top W)}$.
   c) Vérifier l'inégalité fondamentale $\|W\|_2 \leq \|W\|_F \leq \sqrt{2}\|W\|_2$.
3. **Contrôle de Lipschitz en Deep Learning :** Si une activation d'entrée h vérifie $\|h\|_2 = 1$, donner la borne supérieure exacte sur l'amplitude de sortie $\|Wh\|_2$.

Exercice 5 :

Dans une base vectorielle, une requête q et deux documents $d_A, d_B \in \mathbb{R}^3$ ont pour embeddings :

$$q = \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix}, \qquad d_A = \begin{pmatrix} 2 \\ 4 \\ 4 \end{pmatrix}, \qquad d_B = \begin{pmatrix} 2 \\ -1 \\ 0 \end{pmatrix}$$

1. Évaluer le produit scalaire $q^\top d_A$ ainsi que les normes $\|q\|_2$ et $\|d_A\|_2$.
2. Vérifier la saturation de l'inégalité de Cauchy-Schwarz $|q^\top d_A| \leq \|q\|_2 \|d_A\|_2$. Que traduit géométriquement et sémantiquement ce résultat ?
3. Calculer la similarité cosinus Cosine-Sim(q, d_A) et Cosine-Sim(q, d_B).
4. Calculer les distances euclidiennes $d_2(q, d_A)$ et $d_2(q, d_B)$. Pourquoi la distance euclidienne pure échoue-t-elle à capturer l'équivalence sémantique lorsque la longueur des textes varie ?