Université de Tlemcen — **Faculté des Sciences**
Département Informatique — **Ing 4 : IA**
Module : Recherche Opérationnelle — **TP n°2**

TP n°2 : Application des Métriques Vectorielles

Normalisation, K-Means & Algorithme des k-NN

Objectifs du TP : Ce travail pratique a pour but d'exploiter les normes vectorielles (L_1, L_2, L_2^2) dans deux problématiques fondamentales de l'apprentissage automatique :

- **Clustering non supervisé (K-Means) :** Maîtriser l'impact de la distance euclidienne au carré L_2^2 sur la compacité des groupes et l'optimisation de la variance locale.
- **Classification supervisée (k-NN) :** Étudier l'influence de la géométrie des normes L_p (Manhattan vs Euclidienne) sur la construction des voisinages et la frontière de décision.
- **Normalisation des données :** Comprendre le rôle indispensable de la mise à l'échelle (Min-Max) pour garantir l'équité des dimensions dans le calcul des normes.

1 Préliminaire : Normalisation des Descripteurs

Soit un échantillon $\mathcal{X} = \{x_1, \ldots, x_N\} \subset \mathbb{R}^d$. La métrique induite par la norme de Minkowski s'écrit :

$$d_p(x, x') = \|x - x'\|_p = \left(\sum_{j=1}^{d} |x_j - x'_j|^p \right)^{\frac{1}{p}} \tag{1}$$

1.1 1.1 Cas d'étude simple : Le piège des unités de mesure

Considérons 3 observations décrites par deux variables : l'**Âge** (en années, dispersion ≈ 20) et le **Salaire annuel** (en euros, dispersion $\approx 20\,000$) :

$$x_A = (25,\ 2\,200)^\top, \quad x_B = (26,\ 2\,400)^\top, \quad x_C = (45,\ 2\,200)^\top$$

Travail à réaliser :

1. Calculez à la main les distances euclidiennes standard $L_2(x_A, x_B)$ et $L_2(x_A, x_C)$. Quel descripteur capture la quasi-totalité de l'information géométrique ?
2. Que se passe-t-il si l'on exprime le salaire en milliers d'euros ? Concluez sur la nécessité d'une mise à l'échelle.

1.2 1.2 Implémentation requise

Vous devez programmer vous-mêmes la transformation Min-Max pour une matrice $X \in \mathbb{R}^{N \times d}$ afin de ramener chaque variable dans $[0, 1]$:

$$x'_{i,j} = \frac{x_{i,j} - \min_k x_{k,j}}{\max_k x_{k,j} - \min_k x_{k,j}} \tag{2}$$

```
def my_min_max_scaler(X):
    """
    A COMPLETER PAR L'ETUDIANT
    Retourne : X_scaled, x_min (1xd), x_max (1xd)
    """
    pass
```

Question méthodologique : Pourquoi les bornes $(\min_j, \max_j)$ doivent-elles être calculées **strictement** sur l'ensemble d'apprentissage, puis appliquées à l'ensemble de test ?

2 Partie I : Application Métrique I — Algorithme K-Means (Lloyd)

2.1 2.1 Rappel des 4 Étapes Algorithmiques

1. **Initialisation :** Sélection de K centroïdes initiaux $\mu_1^{(0)}, \ldots, \mu_K^{(0)} \in \mathbb{R}^d$.
2. **Affectation (Étape E) :** Assigner chaque point au centroïde le plus proche sous la norme L_2^2 :
$$C_j^{(t)} = \left\{ x_i \;\middle|\; j = \arg\min_{\ell \in \{1,\ldots,K\}} \|x_i - \mu_\ell^{(t)}\|_2^2 \right\}$$
3. **Mise à jour (Étape M) :** Recalculer le barycentre de chaque partition :
$$\mu_j^{(t+1)} = \frac{1}{|C_j^{(t)}|} \sum_{x \in C_j^{(t)}} x$$
4. **Arrêt :** Test de stabilité : $\sum_{j=1}^{K} \|\mu_j^{(t+1)} - \mu_j^{(t)}\|_2^2 \leq \epsilon$ ou nombre maximal d'itérations.

2.2 2.2 Étape 1 : Expérimentation sur un exemple synthétique 2D

On considère le petit ensemble de points 2D suivant :

```
import numpy as np

X_toy = np.array([
    [1.0, 1.0], [1.5, 2.0], [2.0, 1.5],
    [8.0, 8.0], [9.0, 8.5], [8.5, 9.0]
])
# Initialisation manuelle de 2 centroides de depart
mu_init = np.array([[1.0, 2.0], [9.0, 9.0]])
```

À coder :

1. Écrivez une fonction `assign_clusters(X, centroids)` qui affecte chaque point au centre le plus proche sous la norme L_2^2.
2. Écrivez une fonction `update_centroids(X, labels, K)` calculant les nouveaux barycentres.
3. Visualisez graphiquement le déplacement des centroïdes sur le plan (x_1, x_2) pour chaque étape.

2.3 2.3 Étape 2 : Application sur base réelle (*Wine Dataset*)

Chargez la base `load_wine()` ($N = 178$, $d = 13$).

1. Normalisez la base en utilisant uniquement votre fonction `my_min_max_scaler`.
2. Implémentez l'algorithme K-Means complet. À chaque itération t, calculez et affichez en console la valeur du déplacement total sous la norme L_2^2 :
$$\Delta^{(t)} = \sum_{j=1}^{K} \|\mu_j^{(t+1)} - \mu_j^{(t)}\|_2^2$$
3. Vérifiez que ce déplacement diminue bien jusqu'à atteindre la condition d'arrêt $\Delta^{(t)} \leq \epsilon$.

3 Partie II : Application Métrique II — Algorithme des k-NN

3.1 3.1 Rappel des Règles Métriques

Pour une requête $x \in \mathbb{R}^d$ et une base d'apprentissage $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{N}$:

- **Distances induites L_p :** $d_i = \|x - x_i\|_p = \left(\sum_{j=1}^{d} |x_j - x_{i,j}|^p\right)^{\frac{1}{p}}$ ($p = 1$: Manhattan, $p = 2$: Euclidienne).
- **Voisinage :** Tri $d_{(1)} \leq \cdots \leq d_{(N)}$ et sélection des k observations $\mathcal{N}_k(x)$.
- **Vote majoritaire :** $\hat{y} = \arg\max_c \sum_{i \in \mathcal{N}_k(x)} \mathbb{I}(y_i = c)$.

3.2 3.2 Étape 1 : Exemple didactique 2D

Soit la base d'apprentissage réduite suivante avec 2 classes (0 et 1) :

Observation	x_1	x_2	x_3	x_4	x_5	x_6
Coordonnées $(x^{(1)}, x^{(2)})$	$(1,2)$	$(2,3)$	$(3,1)$	$(6,5)$	$(7,7)$	$(8,6)$
Classe y	0	0	0	1	1	1

On soumet la requête de test $x_{test} = (4,4)^\top$.

1. Calculez à la main les distances L_1 et L_2 entre x_{test} et tous les points d'entraînement.
2. Déterminez la classe prédite pour $k = 1$, $k = 3$ et $k = 5$ sous chaque métrique (L_1 et L_2). Les prédictions diffèrent-elles ?

3.3 3.3 Étape 2 : Implémentation et Application sur base réelle (*Breast Cancer*)

Chargez la base `load_breast_cancer()` ($N = 569$, $d = 30$ descripteurs continus).

1. Séparez la base en Apprentissage (75%) et Test (25%).
2. Normalisez les descripteurs avec votre fonction `my_min_max_scaler`.
3. Implémentez la classe `KNNClassifier(k, p)` :

```
class KNNClassifier:
    def __init__(self, k=5, p=2):
        self.k = k
        self.p = p

    def fit(self, X, y):
        """Stockage des donnees d'apprentissage (Lazy learning)"""
        pass

    def predict(self, X_test):
        """Calcul des distances Lp, tri et vote majoritaire"""
        pass
```

4. Comparez la précision (*accuracy*) sur l'ensemble de test pour $k \in \{1, 3, 5, \ldots, 25\}$ en comparant la norme L_1 ($p = 1$) et la norme L_2 ($p = 2$).